





norma-ar

El nuevo **estándar** de consulta sobre
normativa nuclear argentina.

Arquitectura de precisión para profesionales del sector.

El laberinto normativo: El alto costo de la fragmentación.



El desafío operativo no es la disponibilidad, sino la fragmentación extrema. Un profesional invierte horas rastreando una cláusula específica a través de decenas de fuentes heterogéneas.

La fricción estructural de los datos heredados



Lorem ipsum dolor sit amet consectetur adipiscing elit, sed id est consetetur elitr, sed diam nonumy eirmod tempor invididunt ut labore et dolore magna aliquam erat volutpat. Ut no

ERROR



Formatos Opacos

Documentos atrapados en PDFs escaneados (imagen) sin texto seleccionable (sin OCR previo).



Navegación Deficiente

Páginas web gubernamentales con arquitecturas de información complejas y enlaces rotos.




Pérdida Semántica

La extracción tradicional convierte todo a texto plano, destruyendo la estructura lógica original como columnas entrelazadas y notas al pie.

La arquitectura de la claridad: RAG vs. Reentrenamiento.

[Descartado]

Reentrenamiento (Fine-tuning)



Requiere costosas horas de GPU para cada actualización normativa. Difícil trazabilidad de fuentes.

[Implementado]


Arquitectura RAG



El modelo consulta una base de datos vectorial en tiempo real.

Actualizar la normativa significa indexar un documento nuevo en minutos, sin reentrenar el modelo base. Precisión máxima, costo mínimo y trazabilidad absoluta.

El pipeline de precisión: De documentos opacos a conocimiento indexado.



Anatomía de un bloque semántico (Chunking)

Tamaño Óptimo

~500 tokens por fragmento.

Suficiente para abarcar un artículo normativo completo sin diluir la precisión semántica del vector.



Impacto

Evita el riesgo de **extraer oraciones aisladas** fuera de su **contexto crítico** de aplicación.


Zona de Solapamiento

100 tokens de superposición (overlap).


Garantiza que los conceptos técnicos que cruzan los límites del fragmento no pierdan su contexto.

Normalización terminológica sectorial

El OCR comete errores críticos en terminología técnica y siglas. Nuestro pipeline aplica un diccionario de normalización estricto antes de la vectorización para asegurar la recuperación exacta.



El stack tecnológico: Decisiones justificadas.




Inferencia: GPT-OSS 120B
vía Groq

Decisión: arquitectura basada en un proveedor abierto permite adaptarse sin reescribir el sistema.



Vectores: Pinecone vs
Chroma/pgvector

Decisión: Arquitectura serverless requiere persistencia nativa en la nube. Alta disponibilidad sin gestión de infraestructura.



Embeddings: llama-text-embed-v2 (NVIDIA)

Decisión: Ventana de contexto masiva (32.768 tokens) vs alternativas (8.192 tokens), ideal para jerga legal densa sin truncamiento.

Interfaz de consulta sin fricción.

Lenguaje Natural

Permite preguntar como se hablaría con un colega experto ("¿qué pasa si supero el límite de exposición anual?"), superando las limitaciones de la búsqueda tradicional por palabras clave (BM25).



Al superar el límite de exposición anual, se deben activar protocolos de seguridad y notificar a las autoridades competentes. Esto implica una revisión médica inmediata para los trabajadores afectados y un análisis detallado de las fuentes de exposición para implementar medidas correctivas. La normativa establece que las medidas deben incluir la suspensión temporal de las actividades que causaron la sobreexposición hasta que se garantice el cumplimiento de los niveles seguros...

¿qué pasa si supero el límite de exposición anual?



Respuesta Inmediata

La latencia ultrabaja de Groq + Vite permite que el texto se genere en pantalla progresivamente, brindando una experiencia fluida y reactiva.

Validación profesional mediante trazabilidad absoluta.

En el ámbito regulatorio, una respuesta sin fuente carece de valor operativo.

Citas por documento

Cada fragmento recuperado de Pinecone incluye su documento de origen, permitiendo identificar la norma o ley usada en cada respuesta.

Dominio prioritario

El sistema prioriza su índice oficial (+70 documentos) al generar respuestas, reduciendo el riesgo de alucinación normativa frente a un modelo sin contexto documental.

Verificabilidad Inmediata

Permite a los reguladores e ingenieros validar la información directamente contra la fuente original.

Fuente: Ley 24.804

El nuevo estándar de consulta regulatoria



Demo:

`norma-ar.vercel.app`



Citas con fuente clara
(norma o ley usada)



Streaming de respuestas
en tiempo real



Base documental oficial
de la ARN indexada